




Arbre de decision

PRESENTE PAR: MOHAMED VADEL CHEIKHNA SID'MHAMED

1-figure;





2-Type de classification;



2-Type de classification;

A-classification non supervise:

- ▶ Regroupe les objets en classe avec des profils particuliers (données non-apprentissage)
- ▶ . Etablir l'objet à une classe
.calcul le taux d'erreur

B-classification supervise:

- ▶ Classe connu a l'avance (donne d'apprentissage)
- ▶ Utilisation d'algorithme(id3) pour expliquer ou predire a quel groupe appartient nouveau point

Etape:

- ▶ Génération de l'arbre de décision:
A) algorithme (id3..)
Mesure d'incertude (entropie)
- ▶ Élaguer l'arbre de décision

3-generilisation de l'arbre de decision

A-Depart:toutes les instances sont à la racine:

- ▶ C'est le début : toutes les données d'apprentissage sont dans un seul groupe, à la racine de l'arbre (le tout premier nœud).

B-Choisir un attribut + split (test de séparation):

- ▶ algorithme (id3) cherche l'attribut qui permet de mieux séparer les données selon leur classe.

il utilise une mesure d'incertitude (comme le gain d'information, l'indice de Gini, etc.).

C-Partitionner les données:

- ▶ En fonction de la condition (split), on divise les instances :

Chaque branche correspond à une valeur du test, et les données sont distribuées dans les nœuds fils.

D-Traiter chaque nœud fils récursivement:

Pour chaque nœud fils, on répète le processus :

- ▶ On cherche un nouvel attribut
- ▶ On choisit un split
- ▶ On divise les données, etc

E. Arrêter quand on arrive à un nœud terminal:

Un nœud devient terminal (feuille) si :

- ▶ Il n'y a plus d'attributs à utiliser
- ▶ Le nœud est pur : toutes les instances appartiennent à une seule classe
- ▶ Le nœud est presque pur : par exemple, 95 % des données sont dans la même classe
- ▶ Il y a trop peu d'instances pour continuer (ex. moins de 2 : C5.0 arrête à $k = 2$)

F. Étiqueter le nœud terminal

- Une fois qu'un nœud est terminal, on lui attribue une classe.

Il prend la classe majoritaire des instances qu'il contient

G-Exemple:

► ID Ciel | Température | Humidité | Vent | JouerTennis |

►

► 1 Ensoleillé | Chaud Haute | Faible Non

► 2 Ensoleillé | Chaud Haute | Fort Non

► 3 Couvert | Chaud Haute | Faible Oui

► 4 Pluvieux | Doux Haute | Faible Oui

► 5 Pluvieux | Froid Normale | Faible Oui

► 6 Pluvieux | Froid Normale | Fort Non

► 7 Couvert | Froid Normale | Fort Oui

► 8 Ensoleillé | Doux Haute | Faible Non

► 9 Ensoleillé | Froid Normale | Faible Oui

► 10 Pluvieux | Doux Normale | Faible Oui

► 11 Ensoleillé | Doux Normale | Fort Oui

► 12 Couvert | Doux Haute | Fort , Oui

► 13 Couvert | Chaud Normale | Faible Oui

► 14 Pluvieux | Doux Haute | Fort Non

K-solution:





4-élaguer l'arbre obtenue:

Élaguer un arbre de décision (en anglais pruning) consiste à réduire sa taille en supprimant certaines branches ou nœuds peu pertinents, souvent pour améliorer la généralisation

A-Pourquoi élaguer un arbre de décision ?

- ▶ Pour éviter le sur-apprentissage (overfitting)

B-Qu'est-ce que le sur-apprentissage ?

sur apprentissage ou sur-spécialisation (overfitting) C'est quand l'arbre :

- ▶ Apprend trop bien les détails et les bruits de l'ensemble d'apprentissage,
- ▶ Mais échoue à bien classer de nouvelles données (il ne généralise pas bien).

► Exemple 1: "Apprendre par cœur":

imaginons un élève qui prépare un examen :

- Il mémorise par cœur tous les exemples du livre, sans comprendre les idées.

- Le jour de l'examen, on lui pose des questions différentes de celles du livre.

- Résultat : il ne sait pas répondre, car il ne comprend pas vraiment, il a juste récité le livre.

C-Comment réduire ce sur-apprentissage ?

En élaguant l'arbre de décision :

- ▶ On supprime certaines branches (ou sous-arbres) qui n'apportent pas de réelle amélioration à la précision de classification.

D-Que se passe-t-il quand on élague ?

- ▶ L'arbre devient plus simple et plus général,
- ▶ On peut parfois augmenter l'erreur sur les données d'apprentissage,
- ▶ Mais on améliore souvent la performance sur de nouvelles données (meilleure généralisation)

► Exemple2 :

Imaginons que tu entraînes un modèle pour reconnaître des formes (cercle ou carré), et que dans le jeu d'entraînement, il y a une image floue de carré mal classée comme un cercle par erreur.

◆ Modèle normal :

Il va ignorer cette erreur et apprendre les formes générales de cercle et carré. Il ne classera pas parfaitement toutes les données d'entraînement.

◆ Modèle en surapprentissage :

Il va "se forcer" à apprendre aussi cette erreur

► Exemple3: "Apprendre par cœur":

Imaginons une fonction simple :

Des points bien alignés sur une droite, avec un peu de bruit.

◆ Modèle correct :

Il apprend la tendance générale (la droite). Même s'il fait quelques petites erreurs sur le train, il généralise bien.

◆ Modèle en surapprentissage :

Il crée une courbe très complexe qui passe exactement par tous les points d'entraînement, même ceux qui sont dus au bruit.

→ Résultat : catastrophique sur les nouveaux points.



5-comment on faire elaguation
de l'arbre:

A-Pré-élagage (pre-pruning):

On arrête la construction de l'arbre avant qu'il soit trop profond ou trop détaillé.

Comment ?

On impose des limites :

- ▶ Hauteur maximale de l'arbre (ex : pas plus de 5 niveaux)
- ▶ Nombre minimum d'exemples dans un nœud (ex : au moins 10)
- ▶ Gain d'information minimum (si un split n'améliore pas assez, on l'arrête)

B-Post-élagage (post-pruning):

On construit d'abord un arbre complet (qui peut sur-apprendre), puis on simplifie en supprimant des branches inutiles.

Comment ?

Une fois l'arbre terminé, on teste chaque sous-arbre :

- ▶ Est-ce qu'il améliore vraiment la précision sur des données de validation ?
- ▶ Si non, on le remplace par une feuille

6-mesure d'incertude(entropie):

La mesure de l'incertitude est une évaluation quantitative de la variabilité ou de l'imprécision associée à une variable aléatoire ou à une distribution de données.

A-incertude de l'ensemble:

- ▶ Soit deux classe P et N et S un ensemble avec n instance de et p insatnce de P
- ▶ L'information nécessaire pour déterminer si une instance prise au hasard fait partie de P ou N est :

$$I(p,n) = -\frac{p}{p+n} \log_2 \frac{p}{p+n} - \frac{n}{p+n} \log_2 \frac{n}{p+n}$$

B-incertude de sous ensemble:

- ▶ Soient les ensembles $\{S_1, S_2, \dots, S_v\}$ formant une partition de l'ensemble S , en utilisant l'attribut A
- ▶ Tous sous ensemble S_i de S contient p_i instances de P et n_i instances de N
- ▶ l'information nécessaire pour classer les instances dans les sous-arbres S_i est:

$$E(A) = \sum_{i=1}^v \frac{p_i + n_i}{p + n} I(p_i, n_i)$$

- ▶ Le gain d'information par rapport au branchement sur A est :

$$\text{Gain}(A) = I(p, n) - E(A)$$

- ▶ Objectif: minimiser l'information nécessaire donc il faut choisir Choisir l'attribut qui maximise le gain